ChatGPT

Analisi del dataset *Wine* di scikit-learn

Introduzione

Contesto: Immaginiamo di lavorare per un'azienda dedicata all'analisi e alla certificazione della qualità di vini prodotti a basso impatto ambientale. In questo contesto, un modello di *machine learning* addestrato su dati chimici del vino potrebbe supportare i processi di controllo qualità. Ad esempio, analizzando automaticamente la composizione chimica di un vino, il modello può identificare la provenienza e le caratteristiche del prodotto, garantendo che ogni bottiglia rispetti gli standard elevati lungo tutta la filiera produttiva.

Per sviluppare un tale modello, disponiamo del **dataset "Wine"** fornito dalla libreria *scikit-learn*. Questo dataset è un classico esempio di dati enologici usati in Machine Learning per compiti di classificazione. I dati raccolgono i risultati di analisi chimiche su campioni di vino e includono informazioni utili a distinguere diverse tipologie di vino in base al loro profilo chimico [1] [2]. Di seguito presentiamo una ricerca esplorativa su questo dataset, analizzandone il contenuto, le caratteristiche principali e alcune considerazioni preliminari che guideranno la scelta della tecnica di modellazione più adatta.

Panoramica del Dataset *Wine*

Il dataset *Wine* contiene misurazioni chimiche di vini **coltivati in una stessa regione d'Italia** ma provenienti da **tre diverse cultivar (o produttori)** [3]. In totale vi sono **178 campioni** (*istanze*), ciascuno descritto da **13 attributi chimici** misurati su quel campione [4]. Ad ogni campione è associata una **etichetta di classe** (il *target* da predire) che indica **il tipo di vino/la sua origine**. In particolare, le classi possibili sono tre, corrispondenti ai tre differenti gruppi di provenienza dei vini analizzati [5].

Riassunto dei dati:

- **Numero di campioni:** 178 (vino 1: 59 campioni, vino 2: 71, vino 3: 48) [6].
- **Numero di variabili (attributi):** 13 caratteristiche chimiche per ogni vino [4].
- **Tipo di variabili:** tutte **continue** (numeriche reali); non vi sono valori mancanti nel dataset [7].
- **Classi target:** 3 categorie, indicanti l'origine/cultivar del vino. Nel dataset di scikit-learn le classi sono codificate come 0, 1, 2 (corrispondenti a tre regioni o produttori differenti in Italia) [5].

Origine dei dati: questo dataset è stato inizialmente raccolto da un gruppo di ricerca a Genova (Istituto di Analisi dei Composti Farmaceutici e Alimentari) come parte del progetto PARVUS [8]. I dati sono disponibili nel repository UCI Machine Learning sin dal 1991 e vengono spesso utilizzati come benchmark per algoritmi di classificazione. La finalità originaria era **determinare l'origine di un vino sulla base della sua analisi chimica** [9] – un problema perfettamente in linea con il nostro obiettivo di verificare la provenienza e qualità del vino tramite strumenti automatizzati.

Caratteristiche Chimiche Registrate

Ogni campione di vino è descritto da 13 misurazioni chimiche. Queste caratteristiche catturano vari aspetti della composizione del vino – dal contenuto alcolico, all'acidità, ai composti fenolici, fino all'intensità di colore. Di seguito l'elenco degli attributi inclusi nel dataset (con traduzione in italiano):

- **Alcohol (Alcol):** grado alcolico del vino (% in volume).
- **Malic acid (Acido malico):** concentrazione di acido malico (g/l), indicatore di acidità.
- **Ash (Ceneri):** quantità di residuo secco (ceneri) nel vino (g/l).
- **Alcalinity of ash (Alcalinità delle ceneri):** misura dell'alcalinità delle ceneri.
- **Magnesium (Magnesio):** contenuto di magnesio (mg/l).
- **Total phenols (Fenoli totali):** concentrazione totale di composti fenolici.
- **Flavanoids (Flavonoidi):** concentrazione di flavonoidi (sottoclasse di fenoli, importanti per sapore e colore).
- **Nonflavanoid phenols (Fenoli non flavonoidi):** fenoli non-flavonoidi.
- **Proanthocyanins (Proantocianine):** composti polifenolici (proantocianidine).
- **Color intensity (Intensità del colore):** misura quantitativa dell'intensità del colore del vino.
- **Hue (Tonalità del colore):** sfumatura o tonalità del colore del vino.
- **OD280/OD315 of diluted wines:** indice di assorbanza (a 280 nm rispetto a 315 nm) di un vino diluito, correlato alla concentrazione di composti fenolici.
- **Proline (Prolina):** contenuto di prolina (mg/l), un aminoacido presente nel vino.

Queste caratteristiche forniscono un profilo chimico dettagliato di ciascun vino [10]. Ad esempio, gli **indicatori di acidità** (acido malico) e di **contenuto fenolico** (fenoli totali, flavonoidi, proantocianine, ecc.) influenzano il gusto e la qualità del vino. L'**intensità e tonalità del colore** sono legate all'aspetto visivo e all'invecchiamento. La **prolina** è un amminoacido il cui livello può variare in base al vitigno e ai processi di fermentazione. Insieme, questi parametri chimici permettono di distinguere i vini delle tre classi in esame in base alle loro caratteristiche intrinseche.

Distribuzione delle Classi e Statistiche Descrittive

Come detto, i 178 vini sono suddivisi in tre classi: **59, 71 e 48 campioni** rispettivamente nelle classi 0, 1 e 2 [6]. Questo indica che tutte le classi sono ben rappresentate (anche se la classe 2 ha leggermente meno esempi). Prima di scegliere una tecnica di modellazione, è importante esplorare come si distribuiscono i valori delle variabili per ciascun tipo di vino, al fine di capire quali caratteristiche sono più distintive.

Dall'analisi esplorativa emergono alcune **differenze chiave tra le classi**: ad esempio, i vini della **classe 0** tendono ad avere in media un tasso alcolico più **elevato** rispetto agli altri, nonché concentrazioni più alte di composti fenolici (**fenoli totali** e **flavonoidi**) e un contenuto di **prolina** nettamente superiore. Al contrario, i vini della **classe 2** spiccano per un'**intensità colorante** maggiore (colore più intenso) ma mostrano valori inferiori di tonalità (*hue* più bassa) e contenuto fenolico più basso. La **classe 1** presenta valori intermedi in molte misure, fungendo un po' da categoria intermedia tra le altre due in termini di profilo chimico. Queste differenze suggeriscono che alcune variabili avranno un forte potere discriminante. Ad esempio, caratteristiche come flavonoidi e prolina potrebbero contribuire molto a distinguere la classe 0, mentre l'intensità del colore potrebbe essere determinante per riconoscere la classe 2.

Un rapido confronto delle medie per classe conferma queste osservazioni: la classe 0 ha in media ~13.7 di alcol (più alta delle altre), ~2.98 di flavonoidi (molto più alta, contro ~0.78 della classe 2), e ~1115 mg/l

di prolina (più del doppio rispetto alla classe 1) – indicatori di un profilo ricco di alcol e composti fenolici. La classe 2, invece, primeggia in intensità del colore (~7.4 contro ~5.5 di classe 0 e ~3.1 di classe 1) a fronte di un valore di tonalità inferiore (~0.68 vs ~1.06 delle altre) e mostra il contenuto più basso di flavonoidi e il valore OD280/OD315 più basso (indice di fenoli totali più bassi). Queste differenze intrinseche nei dati fanno ben sperare circa la separabilità delle classi attraverso tecniche di classificazione.

Figura 1: Distribuzione dei campioni di vino in uno spazio bidimensionale dopo PCA (Analisi delle Componenti Principali). Ogni punto rappresenta un vino, proiettato sulle prime due componenti principali delle 13 caratteristiche chimiche (dati standardizzati). I colori indicano le tre classi di origine. Si nota che i vini tendono a formare gruppi distinti in base alla classe, segno che il profilo chimico consente di differenziarli.

Come illustrato nella **Figura 1**, una riduzione dimensionale tramite PCA evidenzia che i campioni formano gruppi relativamente separati a seconda della classe di appartenenza. Ciò significa che il profilo chimico dei vini è effettivamente caratteristico per ciascuno dei tre gruppi: pur esistendo un po' di sovrapposizione, la maggior parte dei vini di una data classe si raggruppa nello spazio delle caratteristiche, distinto dalle altre classi. Questo comportamento conferma quanto indicato nella documentazione originaria, ovvero che **il problema è ben posto con classi "ben educate"** e separabili, tanto da essere considerato un buon dataset per testare algoritmi di classificazione senza risultare troppo ostico [7]. In altre parole, il *Wine dataset* presenta una struttura intrinseca favorevole all'apprendimento: le differenze chimiche tra i gruppi di vini sono abbastanza marcate da permettere ai modelli di distinguerli con relativa facilità [11].

Relazioni tra le Variabili

Durante l'analisi preliminare, è utile anche esaminare le **correlazioni** tra le variabili chimiche, sia per comprendere meglio la struttura dei dati sia per individuare eventuali ridondanze (caratteristiche fortemente correlate potrebbero apportare informazione duplicata). Ad esempio, si riscontra una correlazione **positiva molto elevata** *(coefficiente $\approx$ 0.86)* tra **fenoli totali** e **flavonoidi** [12]. Questo è intuitivo, poiché i flavonoidi sono una sottoclasse significativa dei fenoli: un vino con alto contenuto di fenoli totali tende ad avere un alto contenuto di flavonoidi. Altre correlazioni interessanti includono quella tra **intensità del colore** e **prolina**, o tra **alcol** e **prolina** (i vini più alcolici spesso mostrano più prolina, forse indice di uve più mature o processi fermentativi differenti). Invece, variabili come **alcalinità delle ceneri** risultano **inversamente** correlate con alcune misure di acidità e colore. Queste relazioni suggeriscono che non tutte le 13 variabili sono indipendenti; potremmo considerare tecniche di riduzione dimensionale (come PCA stessa, o analisi delle componenti lineari discriminanti) se volessimo semplificare il modello senza perdere troppo informazione. Tuttavia, dato che il numero di feature non è molto elevato (13), possiamo anche scegliere di mantenerle tutte, gestendo le correlazioni durante la modellazione (ad esempio con modelli meno sensibili alla multicollinearità).

Un altro aspetto da notare è la **scala differente** delle variabili: alcune misure hanno range molto diversi (ad esempio la Prolina varia da circa 250 a oltre 1600 mg/l, mentre la tonalità va circa da 0.5 a 1.5). È **consigliato standardizzare** o normalizzare le caratteristiche prima di addestrare certi modelli, in modo da mettere tutte le variabili sullo stesso ordine di grandezza [7]. Fortunatamente, il dataset *Wine* **non presenta valori mancanti** né outlier estremi problematici, quindi non richiede pulizia dei dati, ma solo questa attenzione sulla scalatura.

Implicazioni per la Modellazione

Alla luce dell'analisi esplorativa, possiamo trarre alcune conclusioni utili per impostare la fase di modellazione predittiva:

- **Problema di Classificazione Supervisionata:** Lo scopo è costruire un modello che predica la **tipologia di vino (classe)** a partire dalle 13 misurazioni chimiche. Questo è un tipico problema di classificazione multiclasse. Data la natura ben separata delle classi, vari algoritmi di *machine learning* potranno raggiungere buone prestazioni [11]. In letteratura, questo dataset è spesso usato per testare algoritmi come *Linear Discriminant Analysis (LDA)*, *k-Nearest Neighbors*, *Decision Trees*, *Naive Bayes* o *Support Vector Machines*, che riescono generalmente ad ottenere accuratezze molto alte (spesso >95%).

- **Selezione delle Caratteristiche:** Tutte le caratteristiche chimiche disponibili possono contribuire alla classificazione. Non emergono a prima vista variabili completamente irrilevanti, anche se alcune sono fortemente correlate. In un approccio iniziale potremmo usare tutte le feature, applicando eventualmente tecniche di regularization o PCA/LDA per verificare se la dimensionalità può essere ridotta senza perdita di informazione significativa.

- **Preprocessing Necessario:** Come accennato, **standardizzare i dati** è una buona pratica, specialmente per algoritmi basati su distanza o su gradienti che sono sensibili alle scale delle variabili (ad esempio SVM, rete neurale, k-NN). Lo standard scaling (sottrarre la media e dividere per la deviazione standard di ciascuna variabile) garantisce che attributi come Prolina o Magnesio (con valori numericamente grandi) non dominino indebitamente altre caratteristiche come Hue o Ash nei calcoli delle distanze o dei coefficienti. Questa raccomandazione è evidenziata anche nelle note sul dataset originale [7].

- **Validazione del Modello:** Dato il numero limitato di campioni (178 in totale), sarà importante utilizzare tecniche di validazione incrociata (cross-validation) o una suddivisione train/test robusta per stimare le performance del modello evitando overfitting. Fortunatamente, con 178 esempi si può adottare ad esempio una validazione incrociata a 5 o 10 fold garantendo un buon equilibrio tra training e test su ciascun fold.

- **Metriche di successo:** Essendo le classi bilanciate solo in parte (una classe ha 48 campioni vs 71 della più numerosa), conviene monitorare non solo l'accuratezza globale ma anche metriche per classe (precision, recall per ciascuna classe) o usare la *macro-accuracy* in caso di sbilanciamento. Nel nostro scenario applicativo, è fondamentale minimizzare gli errori di classificazione che potrebbero portare ad una bottiglia di vino certificata erroneamente (es. vino di tipo A etichettato come tipo B). Dunque, potremmo dare importanza anche alla matrice di confusione e valutare se eventuali errori avvengono prevalentemente tra due classi simili (ad es. confondere classe 0 e 1 se i loro profili chimici si sovrappongono leggermente) e capire il perché.

Applicazione nel Contesto Aziendale

Dal punto di vista aziendale, un modello costruito su questo dataset può avere **diverse applicazioni pratiche** nella filiera del vino a basso impatto ambientale. Prima di tutto, la capacità di **identificare automaticamente la provenienza** di un vino tramite analisi chimica è uno strumento prezioso per garantire l'**autenticità** del prodotto: si può verificare che un vino dichiarato di una certa varietà/area corrisponda effettivamente al profilo chimico atteso per quella varietà. Questo aiuta a prevenire frodi o mislabeling.

Inoltre, monitorare i **parametri chimici chiave** (come fenoli, acidità, colore) per ogni lotto di vino permette di assicurare che i vini prodotti rispettino gli standard di qualità stabiliti. Ad esempio, se un vino a basso impatto ambientale deve rientrare in certi intervalli di composti (magari per regolamenti biologici, o per garantire un certo gusto), il modello può allertare qualora un campione presenti valori anomali rispetto alla classe di appartenenza. In pratica, il sistema potrebbe agire come un assistente al controllo qualità: ogni nuova analisi chimica viene data in pasto al modello, il quale **classifica** il vino e potrebbe anche segnalare se quel campione *non* assomiglia a nessuno dei tipi noti (indicando un potenziale fuori standard).

Da notare che il dataset *Wine* in esame riguarda vini di una specifica regione italiana e di tre produttori/cultivar; se la nostra azienda opera su scala più ampia o con diverse tipologie di vino (magari anche di altre regioni o vitigni), il modello andrebbe addestrato/aggiornato con dati rappresentativi di tutte le varietà di interesse. Tuttavia, l'approccio rimane valido: l'analisi chimica multivariata unita a strumenti di machine learning offre un metodo oggettivo e data-driven per la **certificazione della qualità e dell'origine** dei vini. Questo è in linea con le tendenze moderne nell'*enologia avanzata*, dove si integrano competenze chimiche e algoritmi per monitorare la produzione enologica in ottica di qualità e sostenibilità.

Conclusioni

In sintesi, il *Wine Dataset* di scikit-learn fornisce una base solida per sviluppare un modello di classificazione dei vini in funzione delle loro caratteristiche chimiche. L'analisi esplorativa ha mostrato che:

- I dati contengono informazioni ricche e differenzianti per distinguere tre tipologie di vino, con 13 variabili chimiche che delineano il profilo di ciascun campione.
- Le classi sono ben separate nel dominio delle caratteristiche, il che facilita l'apprendimento di un modello accurato [11].
- Alcune feature sono correlate tra loro (ad es. fenoli totali e flavonoidi [12]), ma ogni gruppo di vino presenta tendenze distintive (ad es. classe 0 con più alcol e prolina, classe 2 con colore più intenso, ecc.).
- Non ci sono dati mancanti e il preprocessing principale consisterà nella normalizzazione delle scale per garantire un'efficace applicazione degli algoritmi.

Avendo compreso la struttura del dataset, siamo ora in grado di scegliere e motivare la **tecnica di modellazione** più adatta. Considerando che il problema è supervisionato e non lineare in alcuni rapporti tra feature e classi, potremmo iniziare provando algoritmi come la **Regressione Logistica Multiclasse**, **Alberi di Decisione** o **SVM**, sapendo che anche metodi semplici dovrebbero performare bene. In letteratura questo dataset è stato affrontato con successo anche con tecniche di *Analisi Discriminante Lineare* (che sfrutta proprio la separabilità lineare delle classi) ottenendo ottimi risultati di accuratezza.

Il passo successivo sarà quindi procedere con la costruzione e la validazione del modello di classificazione, tenendo a mente le conoscenze acquisite dall'analisi esplorativa. Con un modello ben addestrato, la nostra azienda potrà implementare un sistema di controllo qualità automatizzato, contribuendo a mantenere alta la reputazione dei suoi vini a basso impatto ambientale grazie a verifiche scientifiche puntuali e affidabili.

Fonti:

- UCI Machine Learning Repository – *Wine Data Set*: descrizione del dataset originale [13] [11].

- Scikit-learn Documentation – *load_wine* dataset: specifiche su dimensioni e attributi del dataset [2] [5].
- Blog *ti_tutoro* (25/09/2018) – *WINE: un dataset di classificazione nato da un progetto italiano*: analisi esplorativa del dataset in italiano [1] [7] [12].
- GeeksforGeeks – *Wine Dataset in Sklearn*: panoramica e contesto d'uso del dataset [2] [14].

---

[1] [3] [4] [7] [12] WINE un dataset di classificazione nato da un progetto italiano | ti_tutoro
https://titutoro.wordpress.com/2018/09/25/wine-un-dataset-di-classificazione-nato-da-un-progetto-italiano/

[2] [5] [8] [14] Wine Dataset in Sklearn - GeeksforGeeks
https://www.geeksforgeeks.org/machine-learning/wine-dataset/

[6] wine_data: A 3-class wine dataset for classification - mlxtend
https://rasbt.github.io/mlxtend/user_guide/data/wine_data/

[9] [10] [11] [13] UCI Machine Learning Repository
https://archive.ics.uci.edu/dataset/109/wine