Analisi dei Vini tramite Machine Learning



Agenda

3 Dataset e Descrizione

6 Analisi Esplorativa

13 Test dei Modelli

14 Linear Discriminant Analysis

17 Random Forest

21 Conclusioni

Dataset e Descrizione

Immaginiamo di lavorare per un’azienda dedicata all’analisi e alla certificazione della qualità di vini prodotti a basso impatto ambientale. In questo contesto, un modello di machine learning addestrato su dati chimici del vino potrebbe supportare i processi di controllo qualità.

Ad esempio, analizzando automaticamente la composizione chimica di un vino, il modello può identificare la provenienza e le caratteristiche del prodotto, garantendo che ogni bottiglia rispetti gli standard elevati lungo tutta la filiera produttiva.



Dataset e Descrizione

Per sviluppare un tale modello, disponiamo del dataset “Wine” fornito dalla libreria scikit-learn.

Questo dataset è un classico esempio di dati enologici usati in Machine Learning per compiti di classificazione.

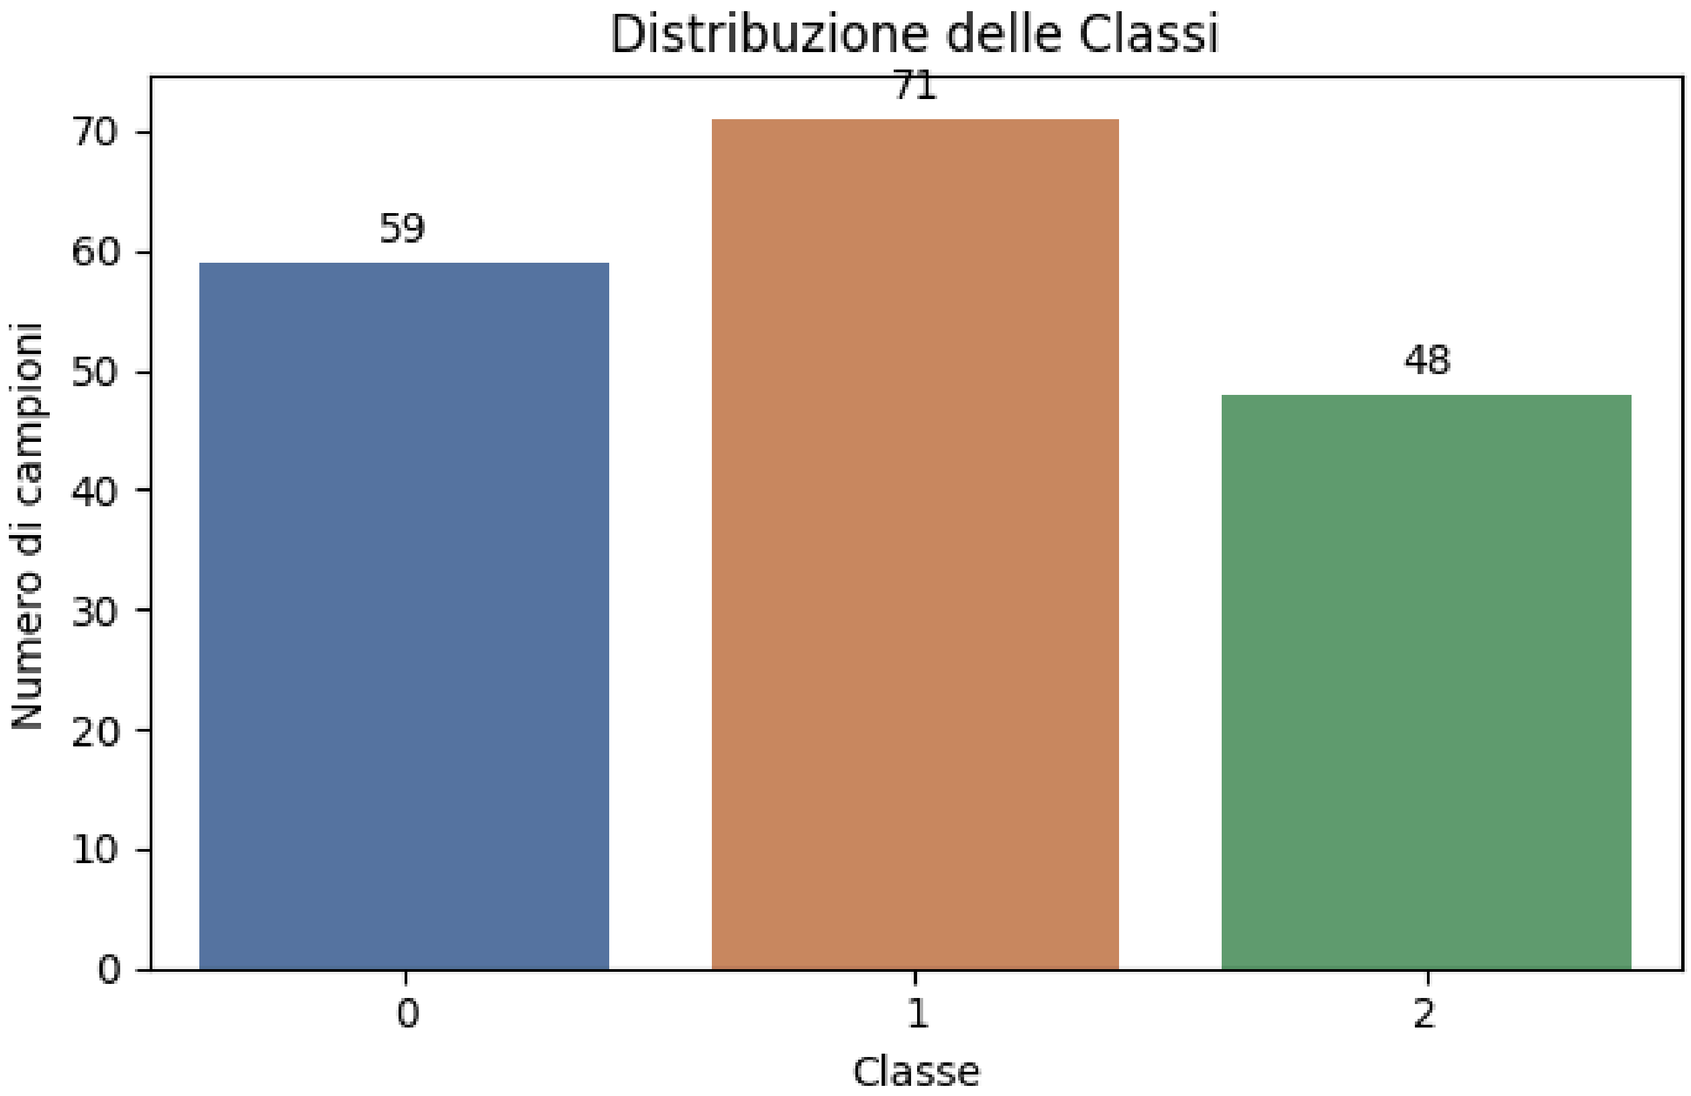
I dati raccolgono i risultati di analisi chimiche su campioni di vino e includono informazioni utili a distinguere diverse tipologie di vino in base al loro profilo chimico.

178 campioni di vino con 13 variabili chimiche
3 classi di qualità (0, 1, 2) abbastanza bilanciate
Variabili includono gradazione alcolica, acidità, fenoli, intensità del colore e proline

Dataset e Descrizione

Feature	Descrizione
Alcohol	grado alcolico del vino (% in volume).
Malic acid	concentrazione di acido malico (g/l), indicatore di acidità.
Ash	quantità di residuo secco (ceneri) nel vino (g/l).
Alcalinity of ash	misura dell'alcalinità delle ceneri.
Magnesium	contenuto di magnesio (mg/l).
Total phenols	concentrazione totale di composti fenolici.
Flavanoids	concentrazione di flavonoidi (sottoclasse di fenoli, importanti per sapore e colore).
Nonflavanoid phenols	fenoli non-flavonoidi.
Proanthocyanins	composti polifenolici (proantocianidine).
Color intensity	misura quantitativa dell'intensità del colore del vino.
Hue	sfumatura o tonalità del colore del vino.
OD280/OD315 of diluted wines	indice di assorbanza (a 280 nm rispetto a 315 nm) di un vino diluito, correlato alla concentrazione di composti fenolici.
Proline	contenuto di prolina (mg/l), un aminoacido presente nel vino.

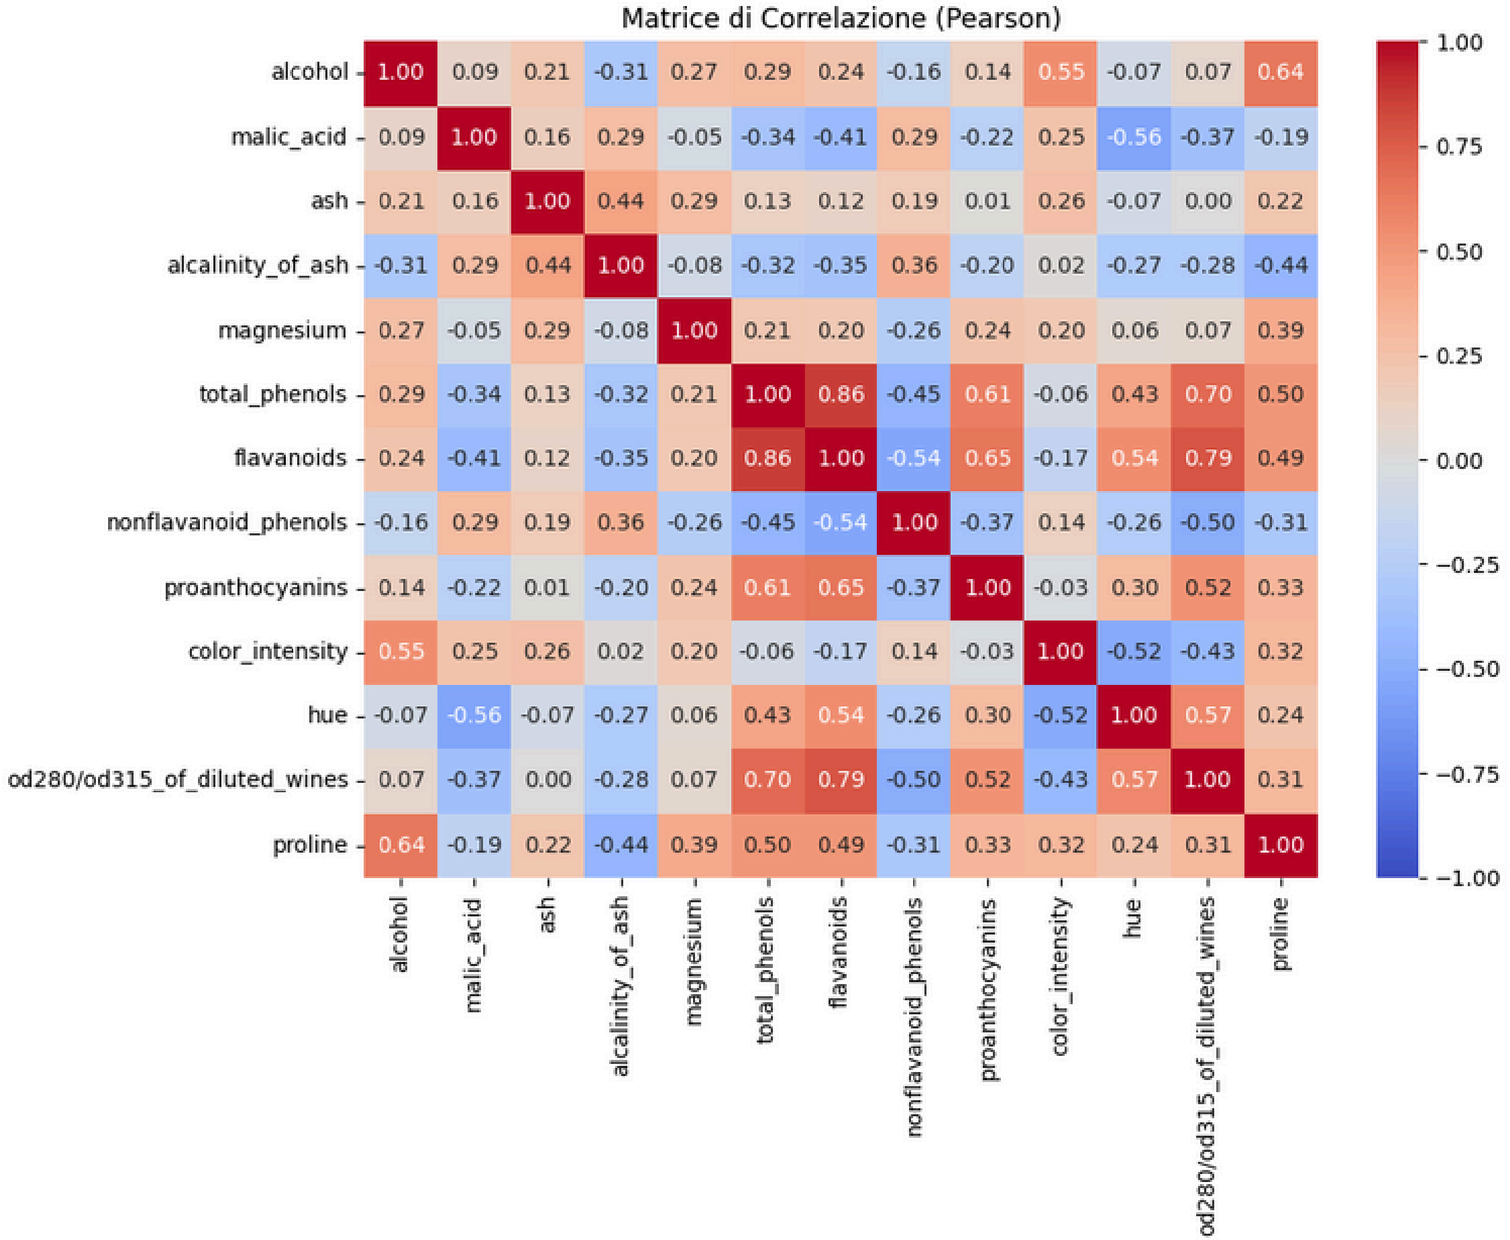
EDA - Distribuzioni e Correlazioni



Classi ben rappresentate

39,9% Classe 1
33,1% Classe 0
27,0% Classe 2

EDA - Distribuzioni e Correlazioni



Si riscontra una **correlazione positiva molto elevata** (coefficiente ≈ 0.86) tra fenoli totali e flavonoidi. Questo è intuitivo, poiché i flavonoidi sono una sottoclasse significativa dei fenoli: un vino con alto contenuto di fenoli totali tende ad avere un alto contenuto di flavonoidi.

Altre correlazioni interessanti includono quella tra **intensità del colore e prolina**, o tra **alcol e prolina** (i vini più alcolici spesso mostrano più prolina, forse indice di uve più mature o processi fermentativi differenti).

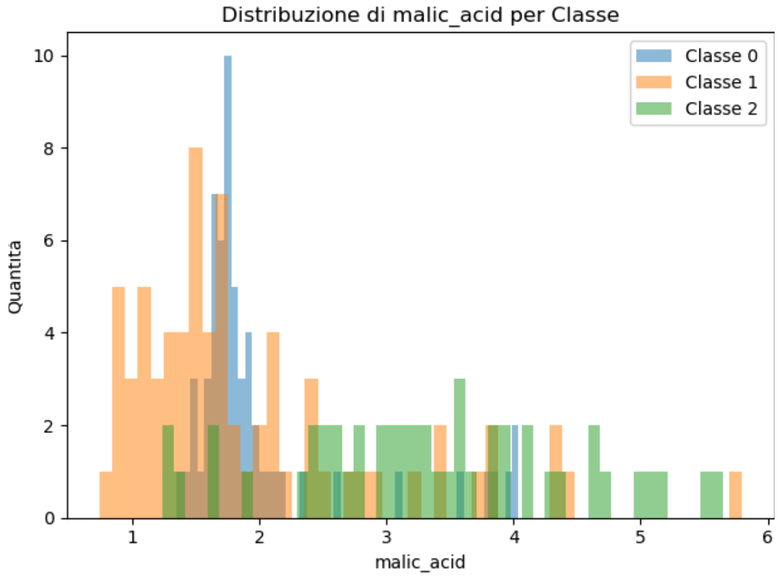
Invece, variabili come **alcalinità delle ceneri risultano inversamente correlate con alcune misure di acidità e colore.**

EDA - Caratteristiche Distintive per Classe



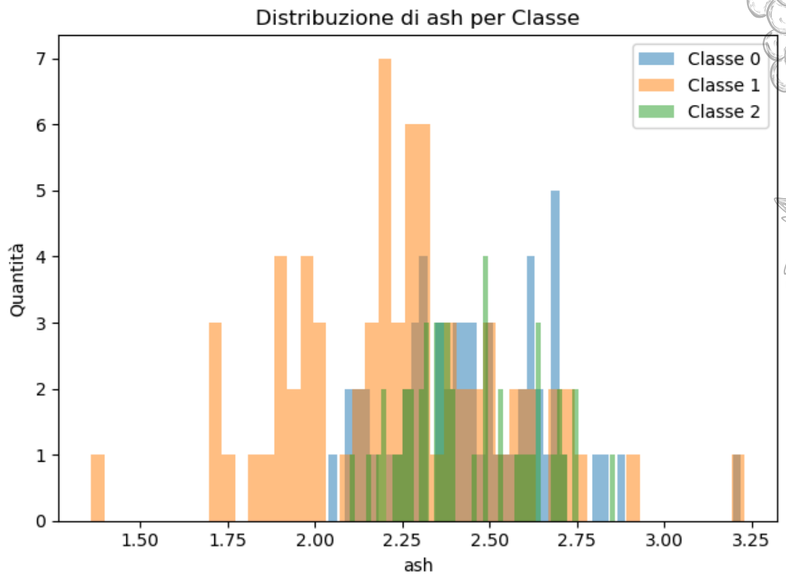
La Classe 0 domina l'area 13.5-14.8 % vol;
La Classe 1 ha la fascia più bassa (11.5-13.2 %)
La Classe 2 occupa la zona intermedia ma raramente supera 14 %.

Un campione ≥ 14 % indica quasi con certezza Classe 0.



La Classe 2 ha code fino a 5-6 g/L e picco attorno a 3-4 g/L;
La Classe 1 è confinata < 2.2 g/L (picco 1.3-1.7)
La Classe 0 si colloca a metà.

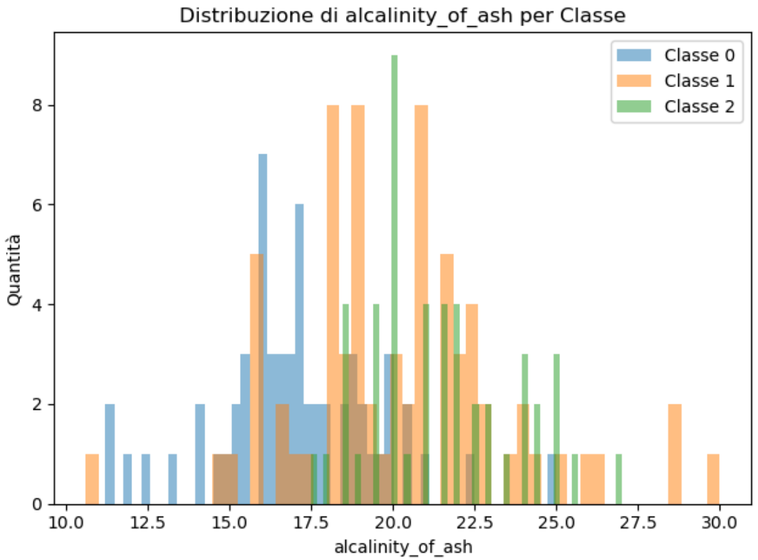
Valori > 3 g/L sono fortemente indicativi di Classe 2.

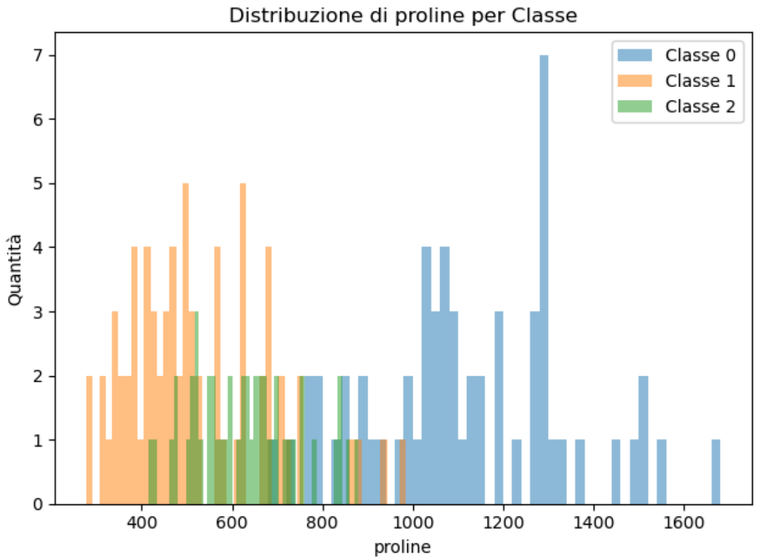


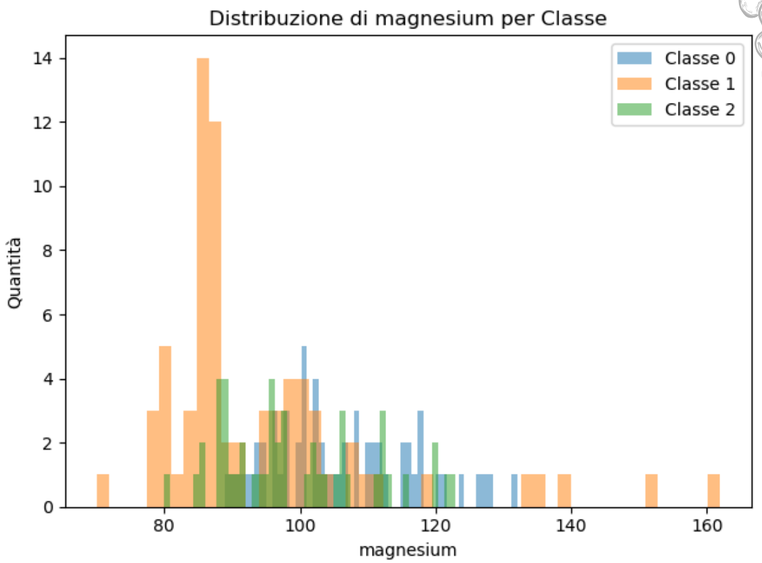
Tutte le classi si sovrappongono fra 2.2-2.6 g/L;
Solo la Classe 0 mostra frequenze apprezzabili sopra 2.7 g/L.

Differenze troppo sottili per essere un driver primario.

EDA - Caratteristiche Distintive per Classe







Classe 0 picco 15-18,
Classe 1 centro 18-22,
Classe 2 20-24 con coda fino a 26-28.

Fornisce un gradiente netto: un valore > 22 indica verosimilmente Classe 2, < 17 suggerisce Classe 0.

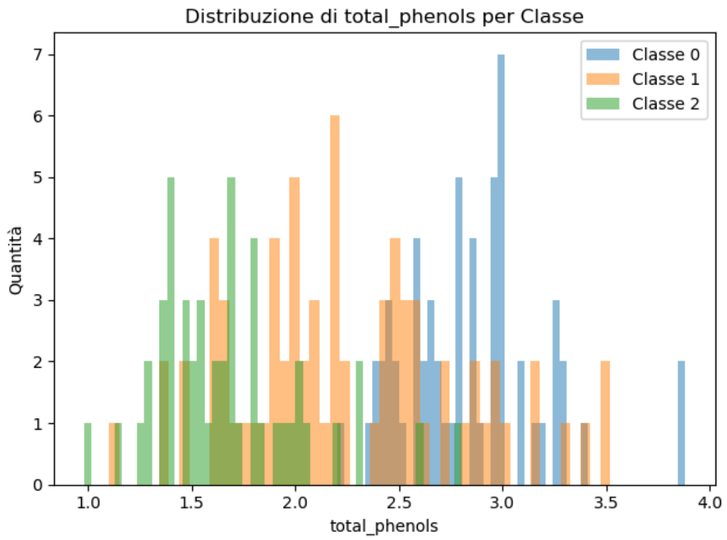
Il picco blu è spostato a destra;
Classe 1 è concentrata 85-100 mg/L;
Classe 2 si sovrappone ma resta tra 90-115 mg/L.

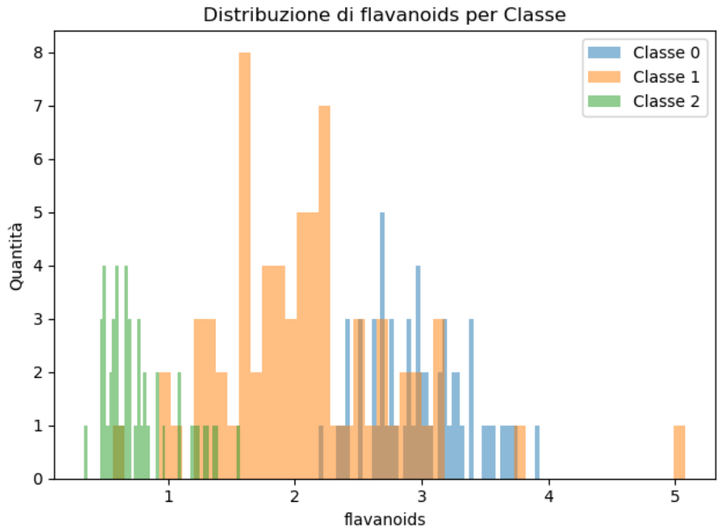
Valori > 115 mg/L segnalano quasi sempre un vino di Classe 0.

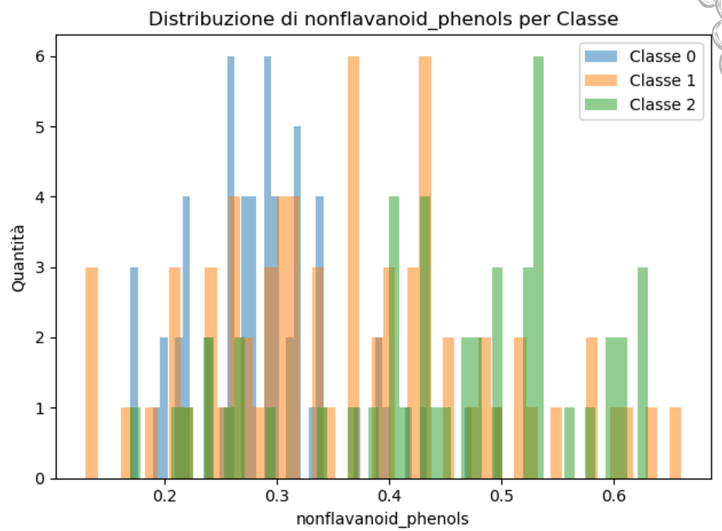
Classe 2 domina area 7–13; Classe 0 occupa 4–7;
Classe 1 è confinata 2–5.

Un campione > 7 u.c. è quasi certamente Classe 2, mentre < 3 indica verosimilmente Classe 1.

EDA - Caratteristiche Distintive per Classe







Classe 0 picco 2.8–3.3 g/L,
Classe 1 2.1–2.6,
Classe 2 1.2–2.0.

Più fenoli totali → probabilità crescente di Classe 0;
Valori < 2 indicano Classe 2.

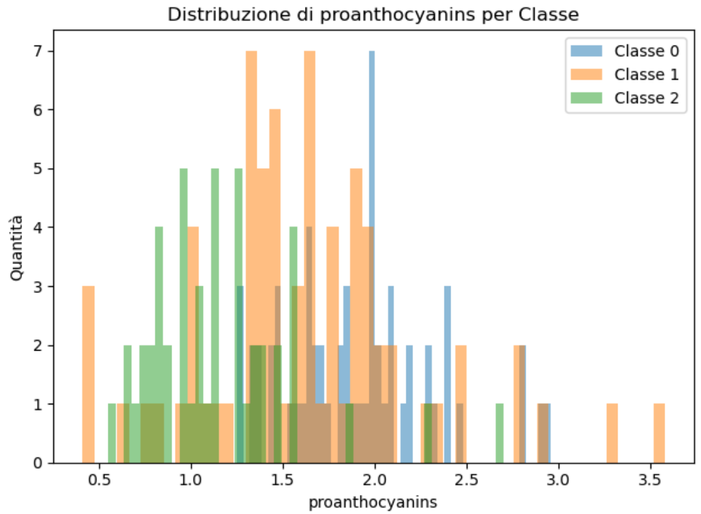
Classe 0 centrata 2.8–3.4,
Classe 1 2.0–2.8,
Classe 2 0.6–1.4.

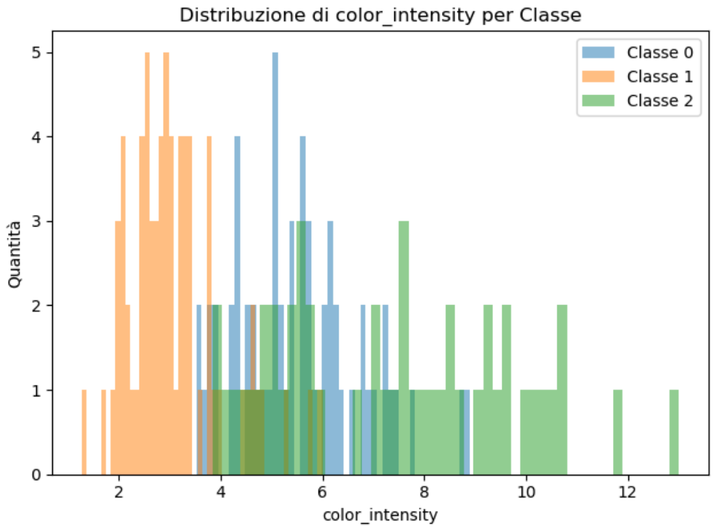
In un solo colpo distingue 0 da 2; Classe 1 rimane intermedia.

Classe 2 ha picco 0.45–0.55 g/L;
Classe 1 0.30–0.45;
Classe 0 0.20–0.30.

Soglia empirica: > 0.45 ⇒ quasi sempre Classe 2.

EDA - Caratteristiche Distintive per Classe





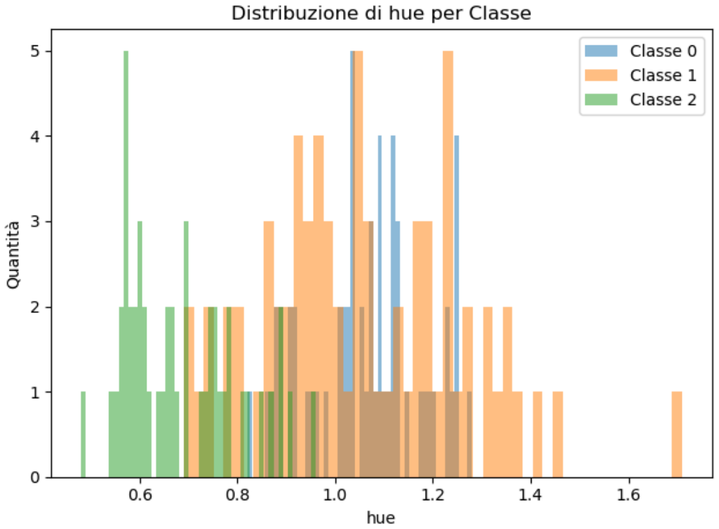
Classe 1 domina 1.4–2.2 con coda fino 3.6;
Classe 0 simile ma leggermente più alta (1.8–2.6);
Classe 2 centrifuga su 0.6–1.4.

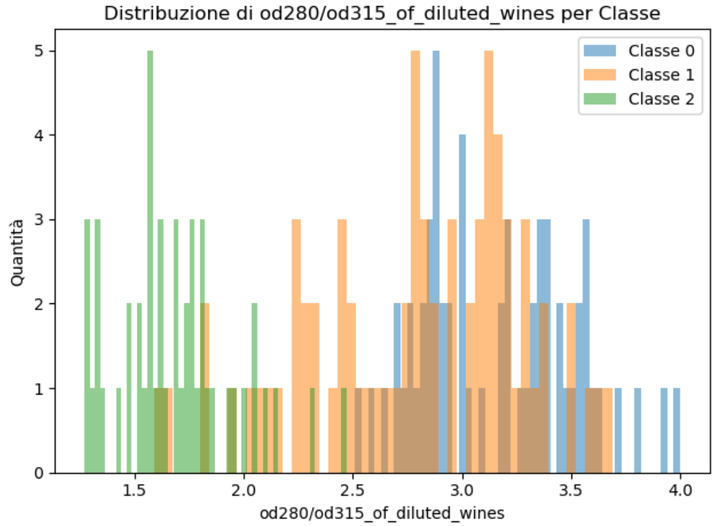
Valori < 1 indicano Classe 2, > 2.5 puntano a Classe 0 o 1 (da combinare con flavanoidi).

Classe 0 concentra i valori alti (≈ 2,9 – 3,7),
Classe 1 occupa la fascia intermedia 2,4 – 3,2,
Classe 2 è relegata a 1,3 – 2,0.

Un campione con indice ≤ 2,1 è quasi sempre Classe 2; ≥ 3 indica in pratica Classe 0.

EDA - Caratteristiche Distintive per Classe





Classe 2 domina la coda bassa (0,55 – 0,80), Classe 0 ruota attorno a 1,05 – 1,20, Classe 1 si estende 0,90 – 1,45 con picco 1,1 – 1,25.

Tonalità < 0,9 rafforza la predizione di Classe 2;
> 1,3 suggerisce Classe 1, specie se il vino non presenta fenoli elevati.

Distribuzione blu fortemente spostata a destra: 1 000 – 1 650 mg/L. Classi 1 e 2 restano fra 300 – 800 mg/L (picco 400 – 600).

Valori > 900 mg/L identificano con altissima probabilità la Classe 0.

Benchmark dei Modelli

Modello	CV mean	CV std	Note rapide
Linear Discriminant	**0,9788**	0,0285	Lineare, interpretabile, ipotesi di covarianze simili
Random Forest	**0,9788**	**0,0173**	Non lineare, feature importance, maggiore stabilità (std più basso)
SVM RBF	0,9786	0,0286	Non lineare, iperparametri (C, γ), poca interpretabilità
Logistic Regression	0,9650	0,0314	Lineare, semplice
k-NN	0,9438	0,0167	Sensibile alla scala, poco interpretabile
Gradient Boosting	0,9434	0,0289	Buono ma più complesso da tarare

Ho, quindi, deciso di testare sia la **LDA** sia il **Random Forest**.

Linear Discriminant Analysis

LDA (solver = svd, shrinkage = None)

Accuratezza media (Nested CV): 0,973 ± 0,028

Accuracy test hold-out (36 campioni): 1,00

Assunzioni: Covarianza omogenea fra classi + separazione linearmente combinabile

Regolazione iper-parametri: Poco da ottimizzare (solver, shrinkage)

Robustezza a outlier / rumore: Moderata; gli outlier possono deformare i coefficienti

Interpretabilità: Alta, i coefficienti lineari direttamente leggibili (peso positivo/negativo)

Driver chimici principali: Proline, Color intensity, Flavanoids, Alcohol, OD280/OD315

Linear Discriminant Analysis - Influenza dei parametri

Ordine (Mean)	Feature	Peso su LD1	Peso su LD2	Cosa indica
1	Flavanoids	**0,286**	0,108	La variabile che più separa le **classi 0 vs 2** (alto nei vini classe 0, basso nei classe 2).
2	Proline	0,172	**0,172**	«Firma» del produttore 0; contribuisce sia a LD1 (vs 2) sia a LD2 (vs 1).
3	Color intensity	0,133	0,104	Spinta verso la **classe 2** (vini più scuri).
4	Alcohol	0,061	0,145	Discriminante importante su LD2: classe 1 < classe 0.
5	Alcalinity of ash	0,071	0,111	Aiuta a distinguere classe 2 (più alcalina).
6	Ash	0,002	0,138	Quasi irrilevante su LD1 ma forte su LD2 (classe 1 vs 2).
7	OD280/OD315	0,110	0,008	Correlato ai flavonoidi; rinforza la separazione 0 vs 2.
8	Hue	0,027	0,078	Valori bassi → classe 2, quindi agisce più su LD2.
9	Malic acid	0,029	0,059	Acidità alta → classe 2, ma contributo complessivo modesto.
10	Total phenols	0,057	0,009	Ridondante con flavonoids; importanza minore.

Linear Discriminant Analysis



Quando scegliere LDA?

- Audit e certificazione, spiegare le decisioni
- Dataset piccolo e lineare
- Uso offline o sistemi embedded

Random Forest



Accuratezza media (Nested CV): 0,979 ± 0,028

Accuracy test hold-out (36 campioni): 1,00

Assunzioni: Nessuna ipotesi di distribuzione; gestisce non-linearità e interazioni

Regolazione iper-parametri: Importante (n_estimators, max_depth, ecc.) – ma stabile

Robustezza a outlier / rumore: Alta (ensemble, bagging)

Interpretabilità: Media: feature importance % (ranking), struttura degli alberi complessa

Driver chimici principali: Proline, Color intensity, Flavanoids, Alcohol, OD280/OD315

Random Forest

Iper-parametro	Valore scelto	Impatto sul modello	Osservazioni chiave
`bootstrap`	**True**	Ogni albero è addestrato su un sotto-campione con rimpiazzo → aumenta la **diversità** interna dell'ensemble.	Con 13 feature e dataset ridotto, il bootstrap riduce il rischio di sovra-adattamento mantenendo alte prestazioni (CV ≈ 0,979).
`n_estimators`	**786**	Numero di alberi.	Quasi 800 alberi garantiscono stabilità statistica; oltre questo valore il miglioramento di CV è marginale.
`max_depth`	**None** (illimitata)	Permette ad ogni albero di crescere finché non si violano gli altri vincoli.	Insieme a `min_samples_split=6` limita la profondità "effettiva": si crea un equilibrio fra bias (basso) e varianza (contenuta dal bootstrap).
`max_features`	**sqrt**	A ogni split si testano $\sqrt{p} \approx 3$–4 feature casuali.	Mantiene la decorrelazione tra alberi e sfrutta la ridondanza presente (fenoli, indici di colore).
`min_samples_split`	**6**	Minimo di campioni richiesti per dividere un nodo.	Impone split solo quando c'è informazione sufficiente, prevenendo rami profondi su pochi vini.
`min_samples_leaf`	**1**	Minimo di campioni in una foglia.	Consente foglie pure (utile per classi sbilanciate); il controllo principale rimane su `min_samples_split`.
CV accuracy (5-fold)	**0,979 ± 0,03**	—	Prestazione allineata agli altri modelli top, senza segni di leakage.
Accuracy test (hold-out 20 %)	**1,00**	—	Conferma la capacità di generalizzare sui campioni non visti.

Random Forest - Feature Importance

Rank	Feature chimica	Importanza*	Interpretazione enologica
1	**Proline**	**0,181**	Aminoacido legato alla maturazione dell'uva → elevato nei vini di classe 0.
2	**Color intensity**	0,171	Classe 2 mostra valori decisamente più alti → discriminante visivo primario.
3	**Flavanoids**	0,170	Comp. fenolici; alto in classe 0, basso in classe 2.
4	Alcohol	0,132	Grado alcolico maggiore nei vini di classe 0.
5	OD280/OD315	0,112	Indice fenolico che rafforza l'effetto dei flavonoidi.
6	Hue	0,062	Tonalità bassa (≈ 0,6–0,8) caratteristica della classe 2.
7	Total phenols	0,052	Conferma del contenuto fenolico totale.
8	Malic acid	0,027	Acidità più elevata nei vini di classe 2.
9	Magnesium	0,026	Lieve differenza minerale tra i vitigni.
10	Alcalinity of ash	0,025	Contributo marginale, ma utile in combinazione con altri parametri.

Random Forest

Quando scegliere Random Forest?



- Nuovi lotti con valori fuori range
- Dataset grande o soggetto a drift
- “Second opinion” di supporto a LDA

Conclusioni e prospettive



- Le 13 variabili chimiche consentono di distinguere tre tipi di vino
- Flavonoidi, proline e intensità del colore emergono come driver principali
- LDA e Random Forest ottengono accuracies ~97–98% (test set 100%)
- LDA è interpretabile e leggera; Random Forest robusta e versatile
- Raccomandazioni: monitorare nuovi lotti, raccogliere più dati e validare periodicamente

Grazie per l'attenzione!

Link al progetto (CORRETTO)



Grazie!

Stefano Nocco







kaggle