

Il naufragio del Titanic

Progetto di Machine Learning

Stefano Nocco

start2impact
UNIVERSITY

Obiettivi

- Predire la sopravvivenza dei passeggeri (Survived 0/1)

- Applicare end-to-end ML: pulizia → feature engineering → modelli → metriche

Il Dataset

In questo progetto utilizzerò un estratto del famoso dataset
Titanic – Machine Learning from Disaster

Questo dataset è il punto di partenza canonico per chi vuole cimentarsi con i modelli supervisionati. Nasce dalla famosa competizione Kaggle lanciata nel 2012 e contiene i dati anagrafici, socio-economici e di viaggio dei passeggeri e membri d’equipaggio del RMS Titanic, affondato nella notte fra il 14 e il 15 aprile 1912.

Lo scopo, didattico più che applicativo, è predire chi sia sopravvissuto al naufragio.

A differenza dell’originale, qui avremmo a disposizione solo alcune features.

Road Map del Progetto

Step 1



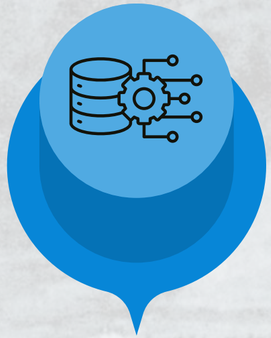
Lettura dei Dati

Step 2



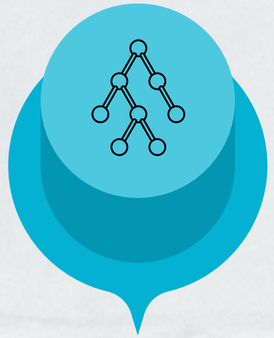
Missing Values

Step 3



Preparazione dei Dati

Step 4



Decision Tree

Step 5



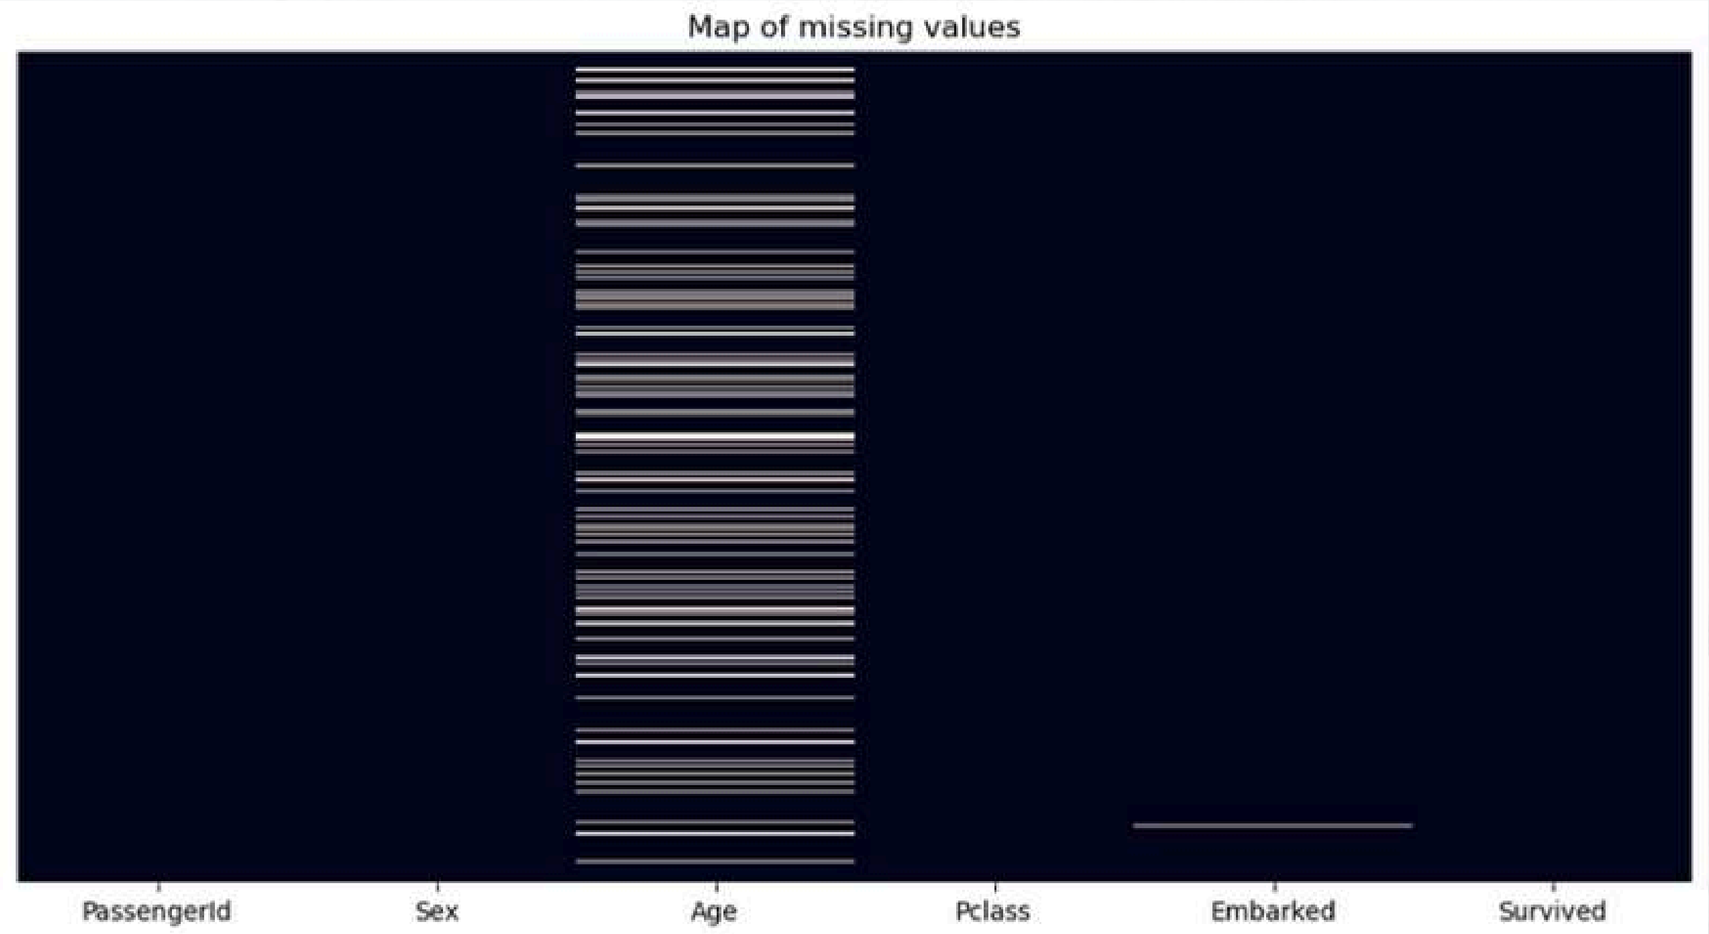
Random Forest

Lettura dei Dati

Il dataset, in seguito all’apertura, si presenta cosi:

	count	unique	top	freq	mean	std	min	25%	50%	75%	max
PassengerId	891.0	NaN	NaN	NaN	446.0	257.353842	1.0	223.5	446.0	668.5	891.0
Sex	891	2	male	577	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Age	714.0	NaN	NaN	NaN	29.699118	14.526497	0.42	20.125	28.0	38.0	80.0
Pclass	891.0	NaN	NaN	NaN	2.308642	0.836071	1.0	2.0	3.0	3.0	3.0
Embarked	889	3	S	644	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Survived	891.0	NaN	NaN	NaN	0.383838	0.486592	0.0	0.0	0.0	1.0	1.0

Missing Values

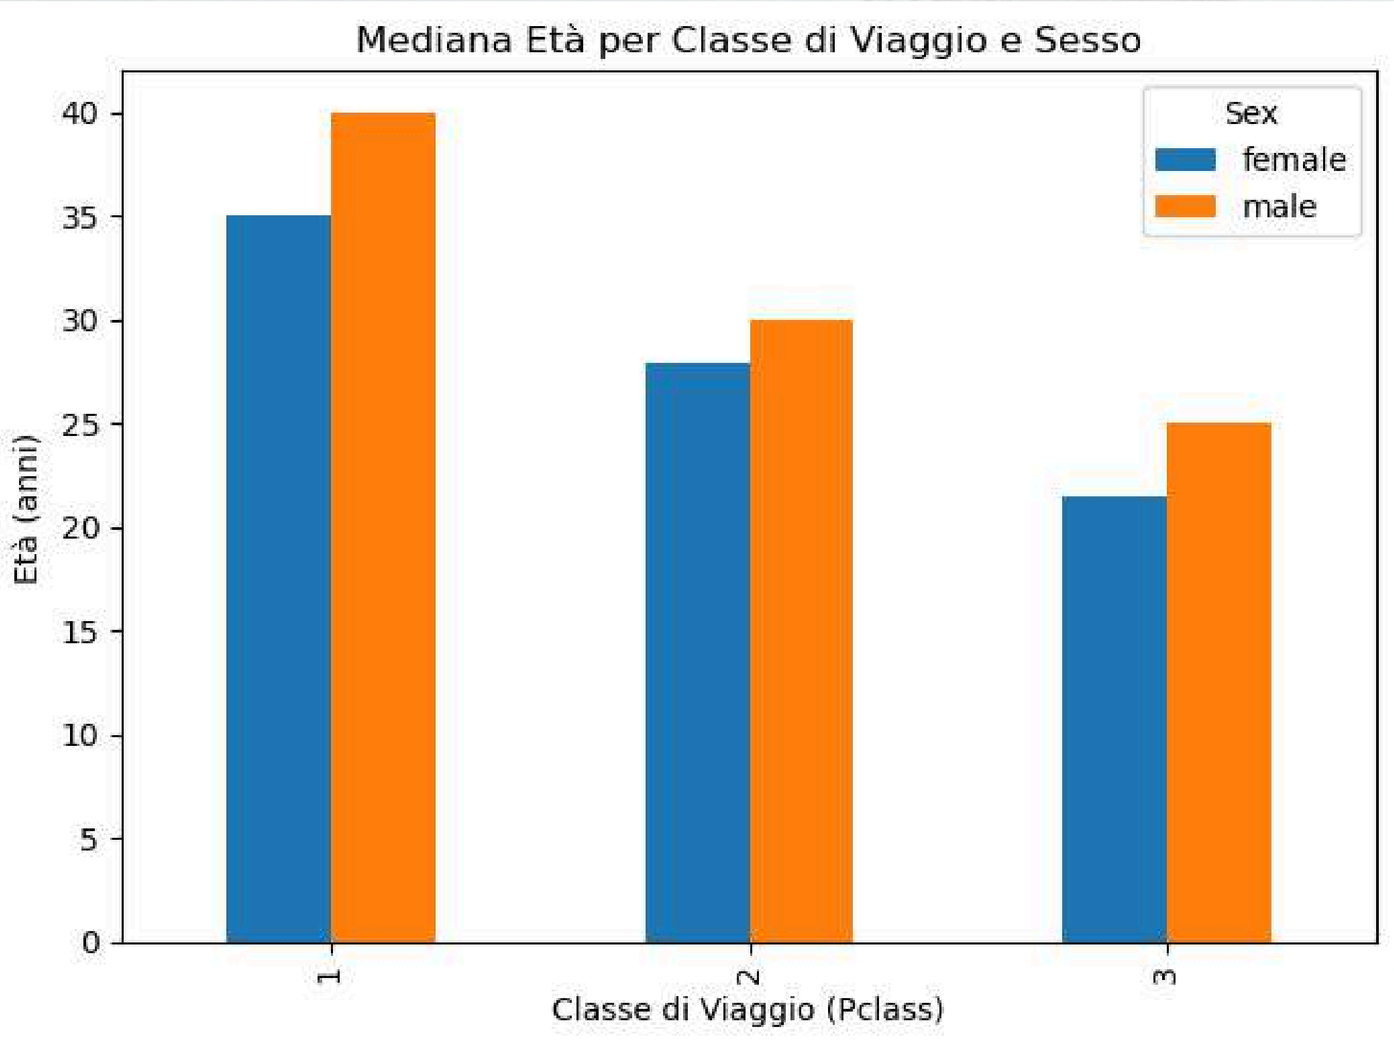


Mediante una funzione da me preparata ho scoperto i seguenti risultati:

```
Missing values per column
Age          177
Embarked       2
dtype: int64

Age            19.865320
Embarked        0.224467
PassengerId     0.000000
Sex             0.000000
Pclass          0.000000
Survived        0.000000
```

Missing Values



Analizzando l'età media dei passeggeri, divisa in base a classe di appartenenza e sesso, emergono differenze socio-demografiche reali:
Ad esempio l'età media delle donne di 1ª classe > uomini di 3ª.

Missing Values

Si sono aperte 3 ipotesi:

- Drop delle colonne
- Drop delle Righe con i valori NaN
- Imputazione dei valori mancanti

```
A_drop_cols  | acc = 0.766 • f1 = 0.655   (n_tr = 501, n_val = 167)
B_drop_rows  | acc = 0.800 • f1 = 0.742   (n_tr = 405, n_val = 125)
C_impute     | acc = 0.784 • f1 = 0.690   (n_tr = 501, n_val = 167)
```

In seguito al test, ho deciso di seguire l’opzione B, rimuovendo le righe con i valori mancanti.

Preparazione dei Dati

Ho utilizzato il OneHotEncoder per la preparazione dei dati:

	Age	Pclass	Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S
81	29.0	3	0	1	0	0	1
173	21.0	3	0	1	0	0	1
664	20.0	3	0	1	0	0	1
751	6.0	3	0	1	0	0	1
208	16.0	3	1	0	0	1	0

Non ho scalato la feature Age perché gli alberi di decisione non dipendono né da distanze né da rapporti di scala, ma basano i loro split in base a dei valori soglia.

Allo stesso modo non ho scalato PClass per i seguenti motivi:

- Gli alberi non soffrono del fatto che 1, 2, 3 siano numeri: il criterio di split si basa su soglie.
- L’ordine “naturale” 1a < 2a < 3a in parte riflette la gerarchia del comfort sociale, quindi non è irrealistico considerarla ordinale.

Decision Tree

Ho, quindi, preparato un albero di decisione, con profondità variabili (2, 5, 10, 25 , Max) e addestrato con i dati di training.

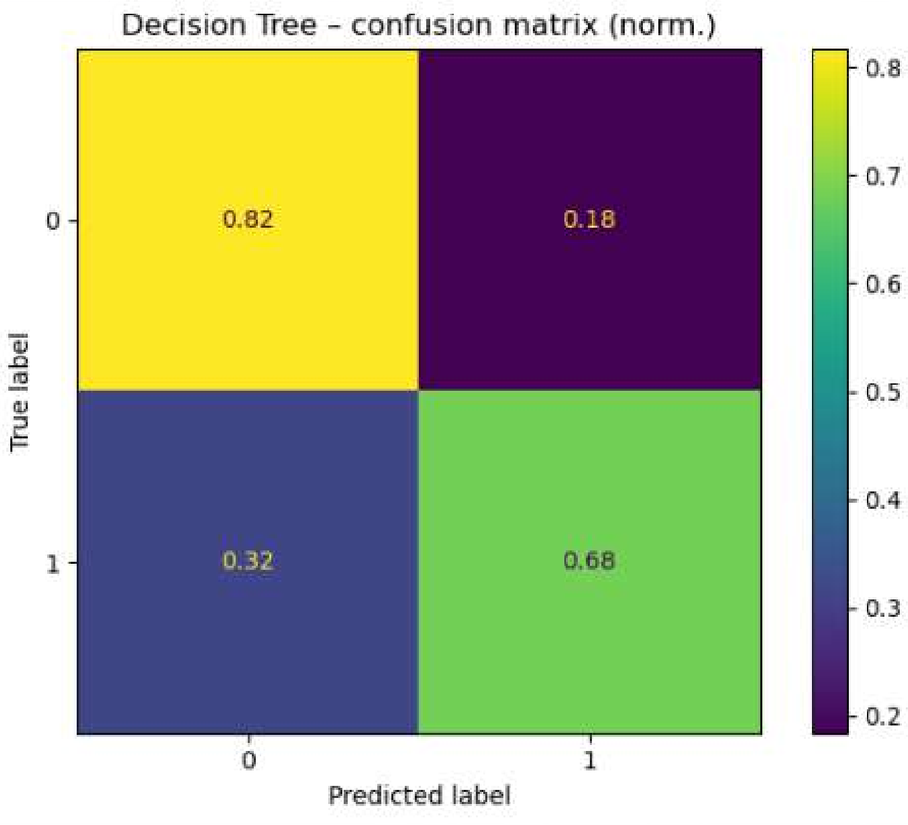
Il modello migliore ha ottenuto un punteggio di **0.808 di accuracy e 0.755 di f1,** con i seguenti parametri:

{'class_weight': 'balanced',
'criterion': 'gini',
'max_depth': 21,
'max_features': 'sqrt',
'min_samples_leaf': 11,
'min_samples_split': 2,
'random_state': 0,
'splitter': 'best'}

Nel test set ha, invece, ottenuto i seguenti valori:

- **acc 0.764**
- **F1 0.699**

Decision Tree



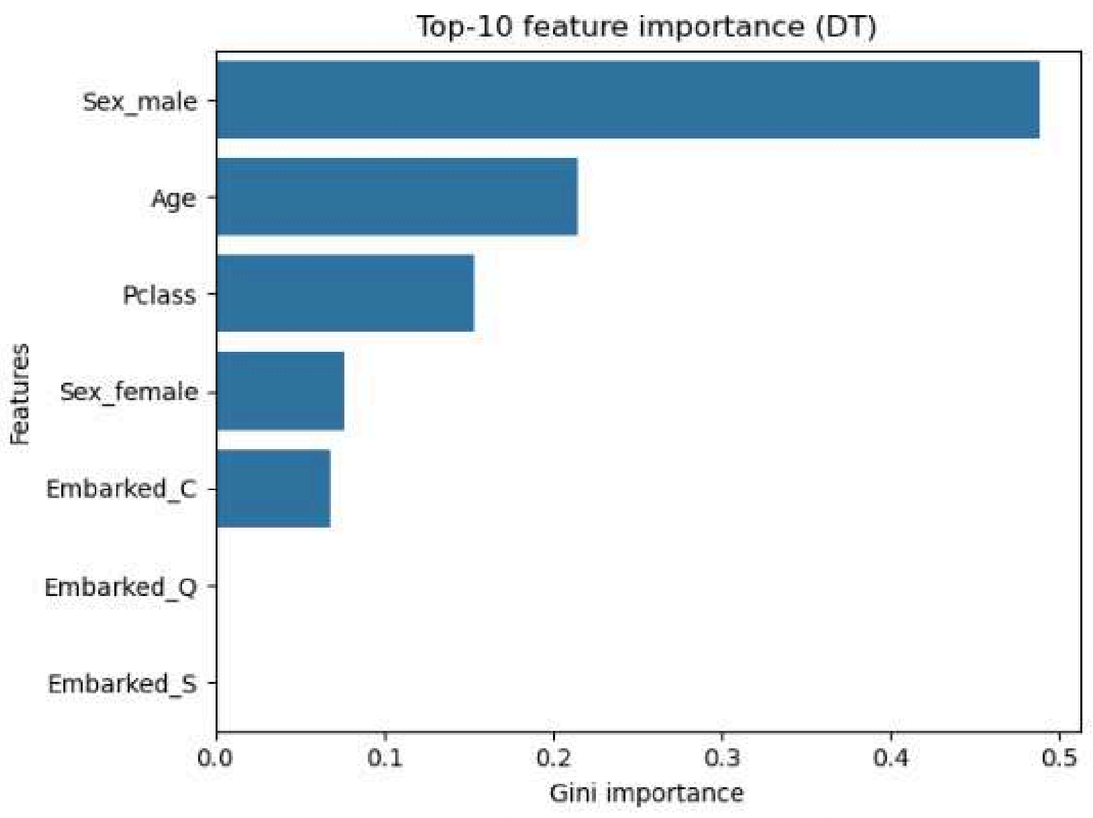
Il modello presenta Buona capacità di riconoscere i non-sopravvissuti. Solo il 12 % degli “0” finisce tra i “salvati”.

Il 68 % dei sopravvissuti viene catturato: 32 % di falsi negativi.

Probabilmente questo succede per i seguenti motivi:

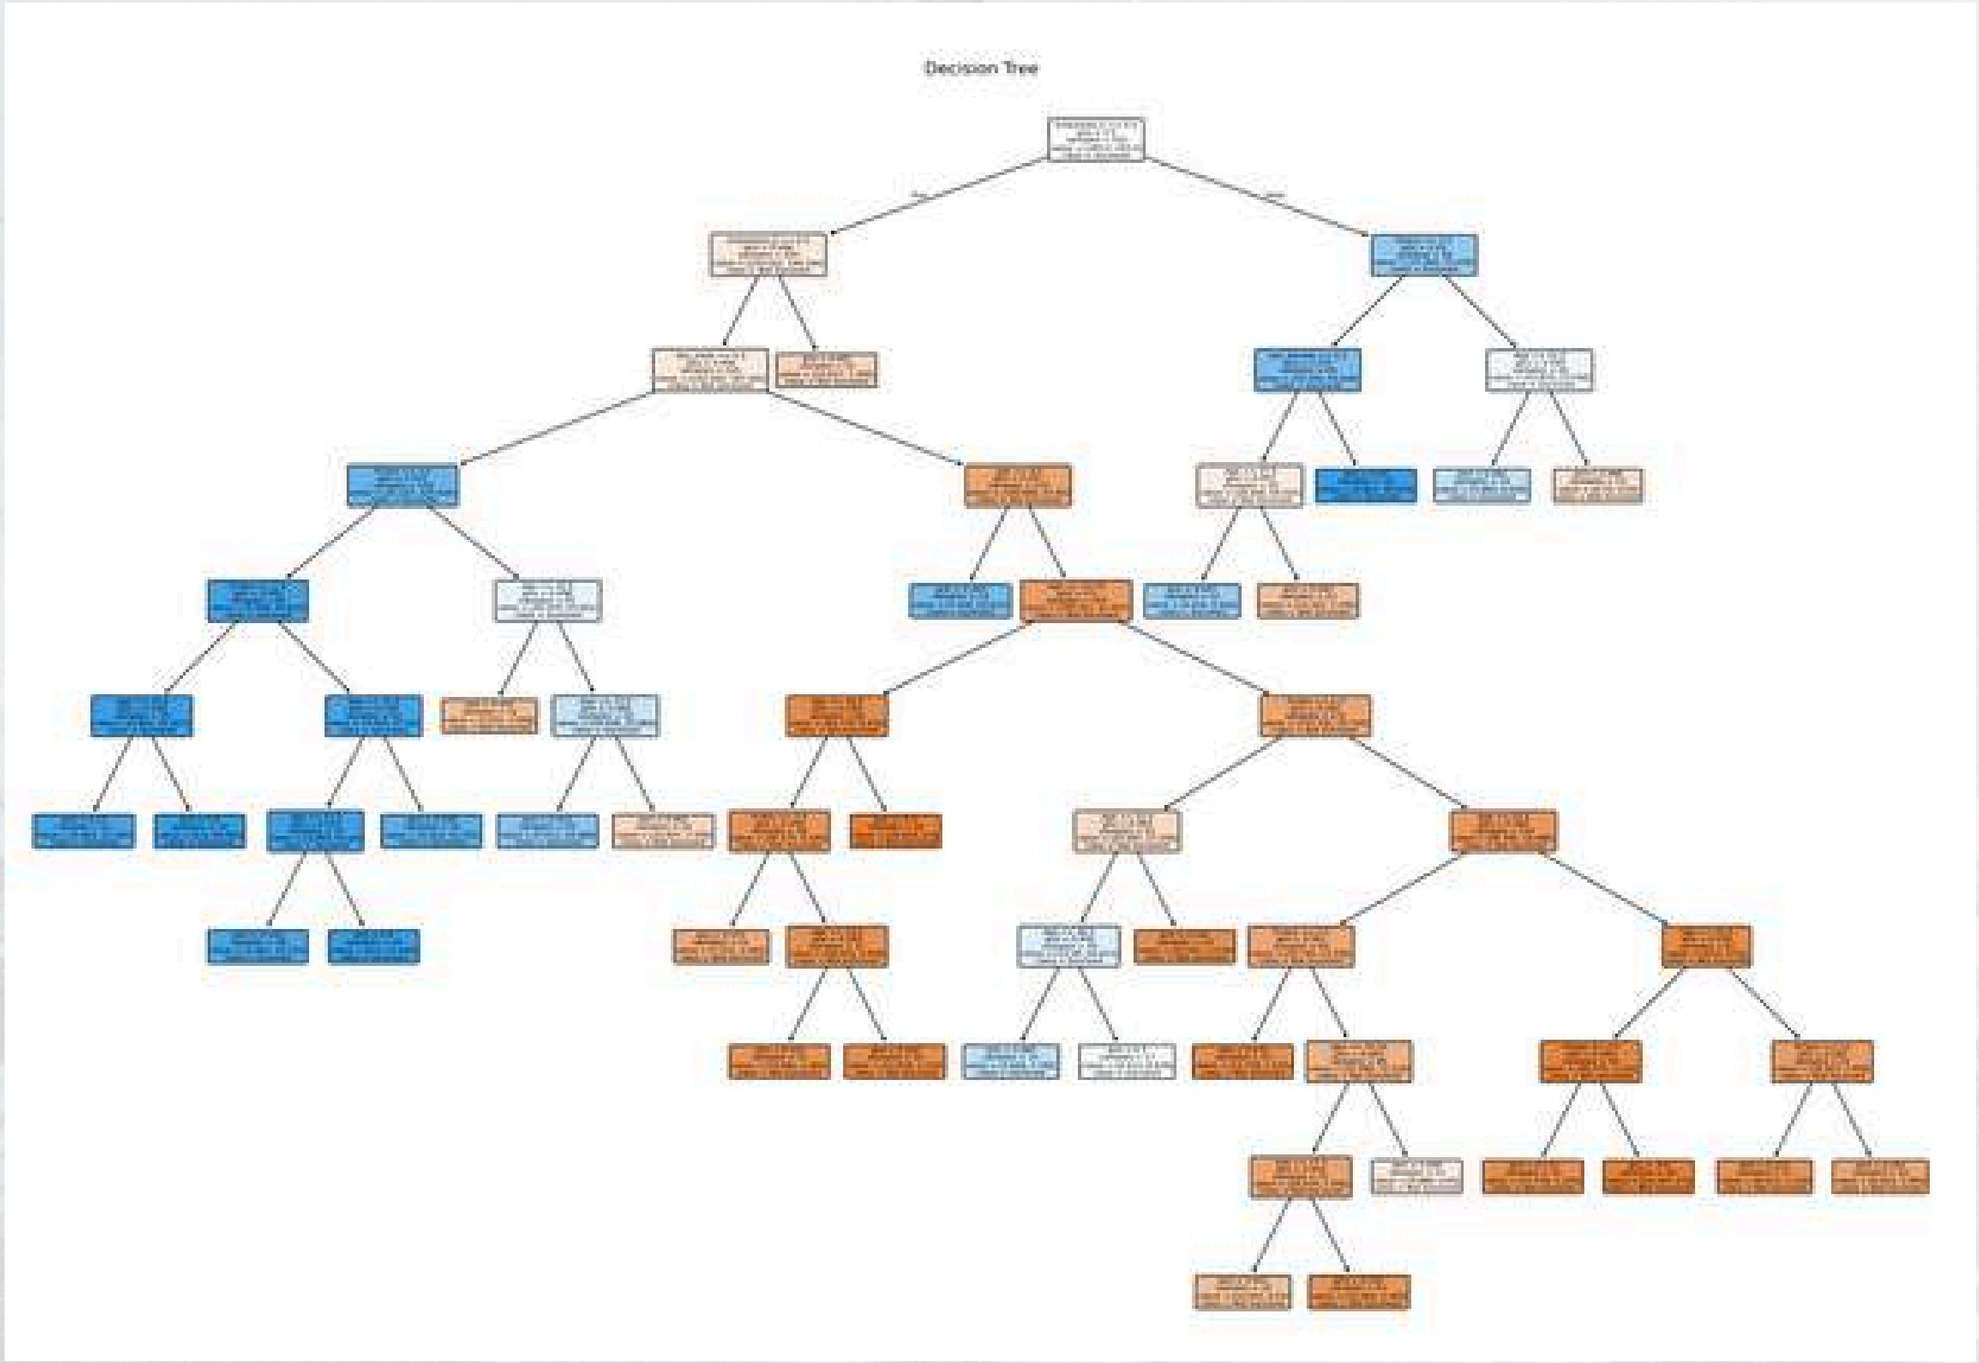
- Over-fit locale: un singolo albero è sensibile a piccoli cambi nei dati; spesso crea regioni troppo “pure” per la classe 0.
- Sbilanciamento delle classi (62 / 38): anche con class_weight="balanced" il DT ha meno flessibilità di ridurre l’errore su minoranza.

Decision Tree



Per quanto riguarda le features, la più importante si conferma essere il sesso (venne data la priorità alle donne), e questo è abbastanza connesso anche alla classe di appartenenza.

Per quanto riguarda l’età, la priorità di salvezza venne data anche ai bambini.


Decision Tree

Link al progetto (CORRETTO_2)



Grazie!

Stefano Nocco



